

# 基于 YOLOv7-tiny 改进的矿工安全帽检测

孙 迟<sup>1</sup>, 刘晓文<sup>2</sup>

(1. 中国矿业大学信息与控制工程学院, 江苏徐州 221116; 2. 中国矿业大学电气与动力工程学院, 江苏徐州 221116)

**摘要:**针对矿工安全帽检测算法准确度不高的问题,提出一种基于 YOLOv7-tiny 网络改进的安全帽检测算法。在 YOLOv7-tiny 网络的基础上,首先针对安全帽这种小目标检测问题,颈部网络融合了  $160 \times 160$  大小特征层的安全帽特征信息,在密集情况下对安全帽的识别效果更好;接着在主干网和颈部网络中间加入 SimAM 无参注意力机制,有效增强安全帽特征提取能力,丰富模型捕获的上下文信息;最后使用 SIOU 损失函数替代 CIOU 损失函数,减小损失自由度,增强网络的鲁棒性。在矿工安全帽数据集上的实验结果表明,改进 YOLOv7-tiny 算法的平均准确度均值达到 98.47%,较 YOLOv7-tiny 提升 3.86%,较 YOLOv5-s、YOLOX-tiny 目标检测算法分别提升 2.90%、7.20%,检测效果优于同类型网络检测效果,在边缘端设备 JetsonTX2 上检测速度达到 28.04 帧/s,满足实时性要求。在不同光线场景下的矿工安全帽检测效果显示,改进 YOLOv7-tiny 算法漏检和误检情况更少,进一步说明了改进算法的有效性。

**关键词:**矿工安全帽检测;小目标检测;YOLOv7-tiny;注意力机制;损失函数

中图分类号:TP391.41;TD76

文献标志码:A

文章编号:2095-2783(2023)11-1250-07

开放科学(资源服务)标识码(OSID):



## Improved detection of miners' safety helmet detection based on YOLOv7-tiny

SUN Chi<sup>1</sup>, LIU Xiaowen<sup>2</sup>

(1. School of Information and Control Engineering, China University of Mining and Technology, Xuzhou, Jiangsu 221116, China; 2. School of Electrical and Power Engineering, China University of Mining and Technology, Xuzhou, Jiangsu 221116, China)

**Abstract:** Facing the problem of low accuracy of miners' safety helmet algorithm, an improved safety helmet detection algorithm based on YOLOv7-tiny network was proposed. Firstly, for the small target detection problem of safety helmet, the neck network integrated the safety helmet feature information of the  $160 \times 160$  size feature layer on the basis of YOLOv7-tiny network, which had a better recognition effect on helmet feature in dense situations. Secondly, SimAM nonparametric attention mechanism was added between the backbone network and the neck network, which effectively enhanced the ability to extract helmet features and enriched the context information captured by the model. Finally, CIOU loss function was replaced by SIOU loss function to reduce the degree of freedom of loss and enhance the robustness of the network. The experimental results on the miners' helmet dataset show that the average accuracy of the improved YOLOv7-tiny algorithm is 98.47%, 3.86% higher than YOLOv7-tiny. Compared with YOLOv5-s and YOLOX-tiny target detection algorithms, the average accuracy rate increases by 2.90% and 7.20%, respectively. The detection effect is superior to the same type of network detection effect. The detection speed on the edge device JetsonTX2 reaches 28.04 frames per second, meeting the real-time requirements. The detection results of the miner's helmet in different light scenes show that the missed and false detections of the improved YOLOv7-tiny algorithm are less, which further illustrates the effectiveness of this improved algorithm.

**Keywords:** miner helmet detection; small target detection; YOLOv7-tiny; attention mechanism; loss function

煤炭资源是我国的基础能源之一,在我国能源结构中占据重要地位<sup>[1]</sup>。然而,随着我国各种经济结构的快速发展,煤矿生产中存在着安全管理不一致、安全问题错综复杂等问题,频繁发生的安全生产事故给社会带来了巨大的损失。在煤矿的开采过程中,矿工的安全问题是放在首位的,而矿工保护自己最直接的方式就是佩戴安全帽,安全帽能够在突发情况时有效保护工作人员头部,进而保证生命安全。矿工未佩戴安全帽的问题时有发生,给矿山安全生

产带来极大的隐患,而传统的人工监督效率比较低,因此针对安全帽检测算法的研究对矿山安全智能化有重大意义。

目标检测的主要任务是找出图像中关注的目标(物体),确定目标的位置及类别,是分类和回归问题的组合。近些年来,随着深度学习的快速发展,目标检测算法也在不断迭代,涌现出不少改进的安全帽识别算法,如:徐先峰等<sup>[2]</sup>提出将 MobileNet 网络引入单次多边框检测(single shot multibox detector,

收稿日期:2023-03-30

第一作者:孙迟(1995—),男,硕士研究生,主要研究方向为目标检测

通信作者:刘晓文,教授,主要研究方向为矿山物联网,ts20060050a31@cumt.edu.cn

SSD)算法应用在安全帽检测中来提高检测速度;郭奕裕等<sup>[3]</sup>通过增加检测头并使用局部稀疏因子衰减算法对 YOLOv4-tiny 网络进行稀疏化训练来提升平均准确度均值;李嘉信等<sup>[4]</sup>基于 YOLOv5-s 设计了一种多空间注意力模块,融合不同层次目标信息,提高小目标检测能力,改善了安全帽检测中漏检误检问题;张翼翔等<sup>[5]</sup>基于改进的 GhostNet 网络在选煤区实现矿工安全帽检测来替代人员检测。虽然目前安全帽检测的方法很多,但针对矿下复杂环境的安全帽检测研究非常少,准确率不高。因此,在具有挑战性和危险性的矿井条件下,提高安全帽识别的准确度以确保矿工的安全非常重要。

本文通过对 YOLOv7-tiny<sup>[6]</sup>网络进行优化来解决安全帽识别准确度低的问题。首先,通过在颈部网络添加包含更丰富信息的特征层,提高小目标检测能力。其次,针对矿下的昏暗环境,在网络的主干和颈部网络中间引入 SimAM<sup>[7]</sup>无参注意力机制,提

高特征提取能力。最后,通过改进损失函数来优化网络的训练,减少损失自由度,提高网络鲁棒性。并在自制的矿工安全帽(Miner helmet)数据集上进行实验,验证方法的有效性。

## 1 YOLOv7-tiny 网络

YOLOv7-tiny 网络是 YOLOv7 网络的精简版,属于轻量型网络,参数只有 600 万左右,相当于 YOLOv7 参数量的 1/6,这使得检测速度较 YOLOv7 提升很大。YOLOv7 网络提出了多分支堆叠模块 E-ELAN,其左支一和左支二均为 1 个卷积标准化激活函数单元,右支一和右支二分别为 3 个和 5 个卷积标准化激活函数单元,将 4 个支路特征融合后进行一次卷积标准化激活操作,而 YOLOv7-tiny 网络对该模块进行了剪枝,且使用了 Leaky ReLU 激活函数,将右边两支路变为 2 个和 3 个卷积标准化激活函数单元,其对比如图 1 所示。

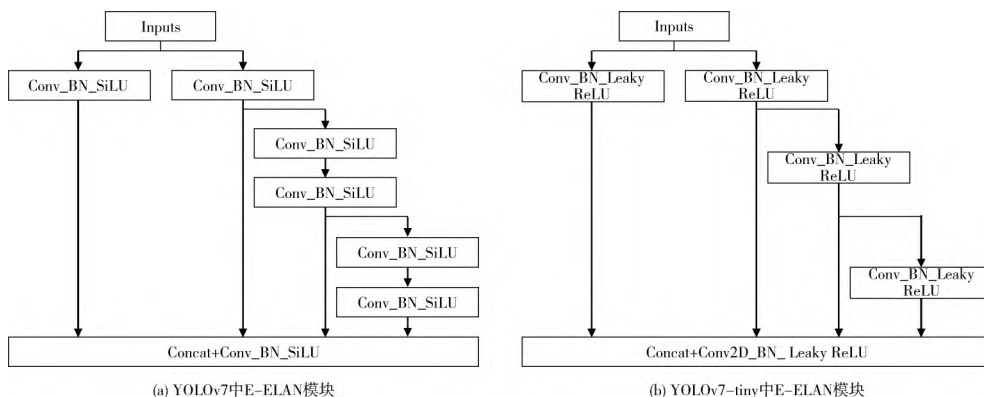


图 1 YOLOv7 与 YOLOv7-tiny 的 E-ELAN 模块对比

Fig. 1 Comparison of E-ELAN modules between YOLOv7 and YOLOv7-tiny

常见的下采样模块通常是大小为  $3 \times 3$ 、步长为 2 的卷积,或者是步长为 2 的最大池化,在 YOLOv7 网络中,将这 2 种方式进行了融合,但在 YOLOv7-tiny 网络中依然使用步长为 2 的最大池化来实现下采样操作。在网络的尾部采用特殊的特征金字塔结构 SPPCSPC,对空间金字塔池化(spatial pyramid pooling, SPP)结构进行残差操作,辅助优化与特征提取,提高网络的感受野。YOLOv7-tiny 网络结构如图 2 所示。

YOLOv7-tiny 从主干网共输出 3 个特征层到颈部网络,当输入为  $(640, 640, 3)$  时,3 个特征层大小分别为  $(80, 80, 128)$ 、 $(40, 40, 256)$ 、 $(20, 20, 512)$ ,通过颈部网络加强特征提取之后,再经头部网络进行输出。以安全帽数据集为例,它的类为 2 种,输出层的大小分别为  $(20, 20, 21)$ 、 $(40, 40, 21)$ 、 $(80, 80, 21)$ ,最后一个维度为 21,21 分解为  $3 \times (1+4+2)$ ,其中 3 表示有 3 种不同的候选框,2 表示每个识别框可以识别的种类,1 表示置信度(该候选框与目标识别重合度越高则该数值越接近 1),4 表示识别目标的坐标

和宽高 4 个参数。YOLOv7-tiny 针对每个特征层只存在 3 个先验框,所以最后的维度为  $3 \times 21$ 。将得到的预测框进行解码、非极大抑制筛选等操作后,网络得到输出结果。

在目标检测网络中,损失函数通常由 3 个部分组成,分别是类别损失、置信度损失、位置损失。其中,类别损失主要在有目标的地方进行判断,通常采用交叉熵损失;置信度损失是区分正负样本的关键部分,主要分为有目标和无目标的置信度损失,同样常采用交叉熵损失计算;位置损失计算预测框和真实框之间的边框损失,通过两者之间的交并比(intersection over union, IoU)计算损失, IoU 计算公式为

$$\text{IoU} = \frac{|b \cap b^{\text{gt}}|}{|b \cup b^{\text{gt}}|} \quad (1)$$

式中:  $b$  为预测框区域;  $b^{\text{gt}}$  为真实框区域;  $b \cap b^{\text{gt}}$ 、 $b \cup b^{\text{gt}}$  分别为 2 个区域的交集和并集。

针对 IoU 无法很好地解决两框相交的问题,广义交并比(generalized intersection over union,

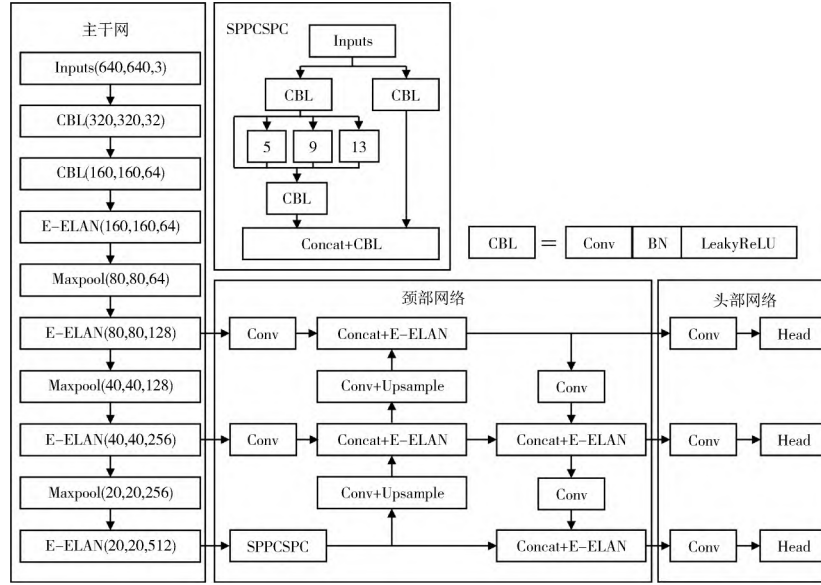


图 2 YOLOv7-tiny 网络结构  
Fig. 2 Structure of YOLOv7-tiny network

GIoU)<sup>[8]</sup> 损失通过计算两框的最小外接矩形来得到两框在矩形中的占比,这样能很好地反映两框相交情况,但计算和收敛速度受到影响。距离交并比(distance intersection over union, DIoU)<sup>[9]</sup> 在 IoU 的基础上回归了 2 个框中心点的欧式距离,加快收敛速度,通过将中心点距离和对角线距离的比值作为惩罚项,避免在损失值较大时难以优化,但 DIoU 仍存在中心点重合、宽高比不同的问题。为了获得更准确的预测框,完整交并比(complete intersection over union, CIoU)<sup>[10]</sup> 在 DIoU 惩罚项的基础上增加了两框之间长宽比一致性。在 YOLOv7-tiny 网络中,置信度损失和类别损失均采用 BCEWithLogitsLoss 函数进行计算,并且采用了 CIoU 作为位置损失函数,考虑了重叠面积、中心点距离、纵横比等因素,CIoU 计算公式如下:

$$L_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(b, b^{\text{gt}})}{c^2} + \lambda\nu, \quad (2)$$

$$\lambda = \frac{\nu}{(1 - \text{IoU}) + \nu}, \quad (3)$$

$$\nu = \frac{4}{\pi^2} \left( \arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2. \quad (4)$$

式中:  $\lambda$  为用于做权衡的参数;  $\nu$  为衡量长宽比一致性的参数;  $\rho$  为预测框和真实框的中心点欧式距离;  $c$  为两框最小外接矩形的对角线距离。可以看出,当长宽比相同时,  $\nu = 0$ , 此时该部分惩罚项失去作用,不稳定。

## 2 改进 YOLOv7-tiny 网络

### 2.1 注意力机制

与现有的通道和空间注意力机制相比, SimAM 注意力机制在特征层的特征映射中考虑空间和通道

维度来推断注意力权值,而不是在原网络中添加参数。基于神经科学理论,该模块的大多数操作运算都是基于定义的能量函数的解来选择,无需额外参数,减少了调整结构花费的时间。基于 Pytorch 实现的 SimAM 注意力模块见算法 1,其中  $\lambda = 1e-4$ ,  $\mathbf{X}$  为输入特征图且输入维度为  $[N, C, H, W]$ ,  $\text{shape}$  为读取维度的长度,  $\text{mean}$ 、 $\text{pow}$ 、 $\text{sum}$  分别为均值、求幂、求和操作,  $\text{sigmoid}$  为激活函数。

算法 1 SimAM 注意力模块

输入:  $\mathbf{X}$  维度  $[N, C, H, W]$   
输出:  $\mathbf{X} * \text{sigmoid}(E_{\text{inv}})$

```

1) function SimamForward( $\mathbf{X}$ , lambda)
2)  $n = \mathbf{X}.\text{shape}[2] * \mathbf{X}.\text{shape}[3]$ 
3)  $d = (\mathbf{X} - \mathbf{X}.\text{mean}(\text{dim}=[2, 3])).\text{pow}(2)$ 
4)  $v = d.\text{sum}(\text{dim}=[2, 3])/n$ 
5)  $E_{\text{inv}} = d / (4 * (v + \lambda)) + 0.5$ 
6) return  $\mathbf{X} * \text{sigmoid}(E_{\text{inv}})$ 
7) end function

```

### 2.2 SIoU 损失函数

在本文中,使用 SCYLLA 交并比(scylla intersection over union, SIoU)<sup>[11]</sup> 损失函数替代 CIoU,在惩罚项中考虑了中心点向量之间的期望角度回归, SIoU 由角度、距离、形状、IoU 这 4 个成本函数组成,其中角度成本的计算方法如图 3 所示。

模型首先将预测带到  $x$  轴或  $y$  轴(以最接近者为准),然后沿着相关轴继续接近,因此角度成本需要判断  $\alpha$  是否小于  $\pi/4$ ,若是则最小化  $\alpha$ ,否则最小化  $\beta$ ,角度成本公式为

$$\Lambda = 1 - 2\sin^2 \left( \arcsin(x) - \frac{\pi}{4} \right), \quad (5)$$




图 3 角度成本的计算方法

Fig. 3 Calculation method of angle cost

$$x = \frac{c_h}{\sigma} = \sin(\alpha). \quad (6)$$

而距离成本代表两框之间中心点距离,结合角度成本表示为

$$\Delta = \sum_{t=x,y} (1 - e^{-\gamma \rho^t}), \quad (7)$$

$$\rho_x = \left( \frac{b_{c_x}^{gt} - b_{c_x}}{c_w} \right)^2, \quad (8)$$

$$\rho_y = \left( \frac{b_{c_y}^{gt} - b_{c_y}}{c_h} \right)^2, \quad (9)$$

$$\gamma = 2 - \Lambda. \quad (10)$$

$\alpha$  越趋向于 0,距离成本的贡献越小; $\alpha$  越接近于  $\pi/4$ ,距离成本的贡献越大。随着角度的增大, $\gamma$

被赋予时间优先的距离值。形状成本公式为

$$\Omega = \sum_{t=w,h} (1 - e^{-\omega_t})^\theta, \quad (11)$$

$$\omega_w = \frac{|\omega - \omega^{gt}|}{\max(\omega, \omega^{gt})}, \quad (12)$$

$$\omega_h = \frac{|h - h^{gt}|}{\max(h, h^{gt})}. \quad (13)$$

式(11)中  $\theta$  对于每个数据集都是独特的值,通常被设置为 1,以限制形状的自由移动。因此,SIoU 公式为

$$L_{\text{SIoU}} = 1 - \text{IoU} + \frac{\Delta + \Omega}{2}. \quad (14)$$

## 2.3 模型改进方案

改进 YOLOv7-tiny 网络结构如图 4 所示。YOLOv7-tiny 在颈部网络从主干网共提取了 3 部分特征信息,大小分别为  $20 \times 20$ 、 $40 \times 40$ 、 $80 \times 80$ ,改进方案首先是针对安全帽这种小目标采取添加  $160 \times 160$  大小的特征层信息堆叠到下面的颈部网络中,然后为了提取更有效的安全帽特征信息,在主干网尾部和颈部网络中间的每个特征层输出增加了 SimAM 无参注意力机制,最后在训练过程中使用了添加角度成本的 SIoU 损失函数。

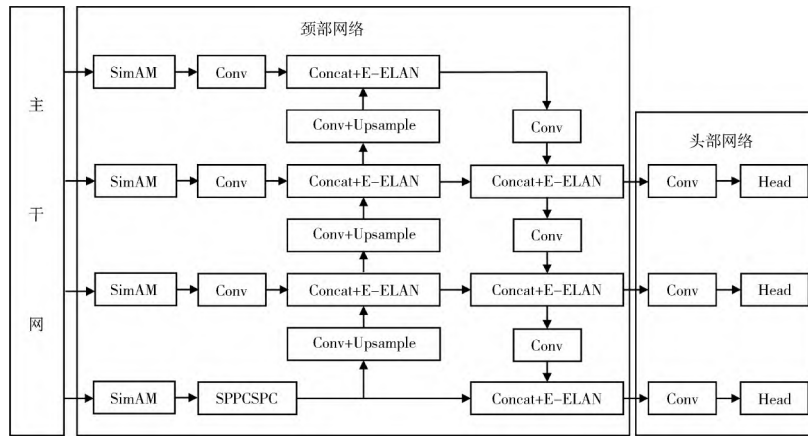


图 4 改进 YOLOv7-tiny 网络结构

Fig. 4 Structure of the improved YOLOv7-tiny network

对于小目标常见的改进方法之一就是添加检测头,但参考了 MHD-Net<sup>[12]</sup> 中的思想,检测头的数量需要根据数据集的特征进行设置,因此没有给网络添加检测头,而是融合更多主干网络层的信息到颈部网络,3.4 节实验证明,在矿工安全帽数据集上,在 YOLOv7-tiny 网络上使用更多的检测头并没有提升平均准确度均值,而融合更多的特征层信息会给网络带来更好的效果。

由颈部网络可以看到,将  $160 \times 160$  特征层引出,该部分特征信息经过注意力机制加强后通过卷积操作,然后与卷积上采样后的  $80 \times 80$  特征层信息融合,最后通过多分支堆叠模块,将输出信息堆叠到下面的网络中,加强特征信息融合。

## 3 实验与分析

### 3.1 实验环境

本文使用的实验平台硬件配置为 AMD Ryzen 5 4600H CPU、GTX 1650(4 GB) GPU、内存 16 GB 的笔记本电脑,操作系统为 Windows 10。模型网络研究采用具有简洁、速度和易用优点的 Pytorch 框架,torch 1.8.1+torchvision 0.9.1+CUDA 11.1。

### 3.2 数据集和训练方法

实验采用自制的矿工安全帽(Miner helmet)数据集,数据集共计 3 000 张图像,主要来自国内视频网站中不同矿井的真实纪录片,图像标注工具为 La-

belImg,标注格式为 VOC 格式。所有实验皆在同一设备上,将数据集划分为训练集、验证集和测试集,其中(训练集+验证集):测试集划分比例为 9:1,训练集:验证集划分比例为 9:1,实验数据结果为测试集结果,输入图片大小为  $640 \times 640$ 。训练策略如下:迭代次数 Epoch 设置为 100,使用 Adam 优化器,初始学习率为 0.001,采用余弦退火学习策略,最小学习率为 0.000 5,预训练权重采用 PAS-CAL VOC 2007+12 数据集的权重。

在数据集的预处理上,本文采用的传统方法主要包括对图像进行随机的裁剪、缩放、翻转、色域转换以及加入随机的噪声处理,此外,还使用了马赛克数据增强的方法。马赛克数据增强将 4 张图片进行拼接后获得 1 张新的图片,且在批标准化(batch normalization,BN)计算时会同时计算 4 张图片的数据,这极大地丰富了图片中检测物体的背景,扩大了数据集。马赛克数据增强处理过程如图 5 所示,其中图 5(a)为读取的 4 张原图,图 5(b)为处理后的图片。首先依次读取 4 张图片,然后对 4 张图片进行翻转、缩放、色域转换等操作并将它们放置在 4 个方位,接着对其进行图片标注框的结合。由于马赛克数据增强生成的训练图片脱离自然图片真实场景,在实际训练中,前 70% 个 Epoch 开启马赛克数据增强方法。



图 5 马赛克数据增强方法

Fig. 5 Mosaic data enhancement method

### 3.3 衡量指标

目标检测模型中通常采用召回率、准确率、计算量、参数量、平均准确度均值(mean average precision,mAP)、每秒处理图片帧数(frames per second,FPS)来衡量模型的性能。其中,平均准确度均值是计算所有类别  $P$ - $R$ (准确率-召回率)曲线下面积的平均值,计算公式如式(15)所示;平均准确度(AP)是计算某一类  $P$ - $R$  曲线下面积,计算公式如式(16)所示;准确率( $P$ )、召回率( $R$ )的计算如式(17)、式(18)所示。

$$mAP = \frac{1}{K} \sum_{i=1}^K AP_i, \quad (15)$$

$$AP = \frac{1}{r} \sum_{i=1}^r p_i, \quad (16)$$

$$P = \frac{TP}{TP + FP}, \quad (17)$$

$$R = \frac{TP}{TP + FN}. \quad (18)$$

式中:TP 为检测结果为正的正样本,即佩戴安全帽被预测为佩戴安全帽;FP 为检测结果为正的负样本,即未带安全帽被预测为佩戴安全帽;FN 为检测结果为负的正样本,即佩戴安全帽被预测为未佩戴安全帽; $r$  为不同召回率的取值, $p_i$  为不同召回率下的准确率。此外,mAP@0.5 表示 IoU 为 0.5 时的 mAP 值,mAP@0.95 表示 IoU 在 0.5~0.95 中间隔 0.05、10 个 IoU 阈值下的 mAP 均值。在相同条件下采用各轮次中损失最低的一组权重文件进行测试,使用召回率、准确率、平均准确度均值及 FPS 作为评价指标。

### 3.4 实验过程与结果分析

为了验证改进的 YOLOv7-tiny 中所使用的各个模块对 YOLOv7-tiny 的优化作用,进行网络的消融实验。

常见改进目标检测方法可以在网络中添加检测头,以帮助网络检测更小目标的信息,本文采用堆叠上层信息融入下层网络的方法,并没有采取添加检测头的方法,对比实验结果见表 1,其中 H2 表示 2 个检测头、H3 表示 3 个检测头、H4 表示 4 个检测头,+1 表示融合上层信息。可以看出,增加检测头使网络性能变差,并没有给准确度带来提升,而使用 2 个检测头时虽然同样使网络性能变差,但在 2 个检测头上融合上层信息后效果有提升,在 3 个检测头的基础上融合上层信息后,较原网络同样得到了提升。

表 1 检测头对比实验

Table 1 Comparison tests of detection head

方案	mAP@0.5/%	mAP@0.95/%	R/%	P/%
H2	93.33	78.0	89.91	92.45
H2+1	93.74	77.1	91.74	89.29
H3	94.61	79.2	92.66	91.82
H3+1	94.77	79.6	91.74	91.74
H4	91.02	71.0	79.82	94.57

为了验证各模块的有效性,进行了堆叠结构、注意力机制和损失函数的消融实验,见表 2。可知:实验③在主干网和颈部网络中间加入注意力机制对网络提升了 1.51%,实验④改进网络损失函数提升了 1.03%;在⑤~⑧的组合实验中,模块的融合也对网络有不同程度的提升,加入注意力机制的网络平均准确度均值均略高,在实验⑧中,最高平均准确度均值达到了 98.47%,对比原网络共提升了 3.86%,证明了改进方法的有效性。改进前后损失函数对比如图 6 所示。

### 3.5 与其他算法的对比

为了比较改进 YOLOv7-tiny 模型与其他主流目标检测算法在矿工安全帽数据集上的性能,将改进

表 2 消融对比实验  
Table 2 Ablation contrast experiments

方案	H3+1	SimAM	SiOU	mAP@0.5/%	mAP@0.95/%	R/%	P/%
①				94.61	79.2	92.66	91.82
②	✓			94.77	79.6	91.74	91.74
③		✓		96.12	79.4	92.66	91.82
④			✓	95.64	79.9	93.58	92.73
⑤	✓	✓		96.10	79.5	92.66	90.18
⑥	✓		✓	95.43	80.0	94.50	90.35
⑦		✓	✓	97.75	79.0	92.66	92.66
⑧	✓	✓	✓	98.47	80.5	96.33	90.52




图 6 损失函数对比  
Fig. 6 Loss function comparison chart

算法与 YOLOv4-tiny、YOLOv5-s、YOLOX-tiny、YOLOv7-tiny 等同样轻量级网络进行比较,结果见表 3。可以看出,相较于 YOLOv4-tiny、YOLOv5-s、YOLOX-tiny、YOLOv7-tiny,改进算法在平均准确度均值方面分别提升了 9.23%、2.90%、7.20%、3.86%,同时召回率较原网络 YOLOv7-tiny 提升了 3.67%,验证了改进算法的可行性。

表 3 改进算法与其他算法实验对比

Table 3 Experimental comparison between the improved algorithm and other algorithms

算法	mAP@0.5/%	R/%	P/%	FPS/(帧·s <sup>-1</sup> )
YOLOv4-tiny	89.24	83.49	89.22	74.33
YOLOv5-s	95.57	94.50	91.15	35.86
YOLOX-tiny	91.27	86.24	90.38	37.33
YOLOv7-tiny	94.61	92.66	91.82	47.41
本文	98.47	96.33	90.52	45.24

在 YOLOv7-tiny 的基础上,改进算法的平均准确度均值、召回率均有一定程度的提升。从检测速度来看,由于网络中加入了注意力机制等模块,导致推理速度变慢,相较于 YOLOv7-tiny 下降了 2.17 帧/s,不过其检测速度(45.24 帧/s)仍然满足实时性的要求。

为了验证改进 YOLOv7-tiny 模型在边缘端设备的检测效果,将其部署在 Jetson TX2 上。模型部署步骤如下:首先将 Pytorch 模型转换为 Onnx 中间件并进行简化,然后解析 Onnx 文件构建 TensorRT 推

理引擎,加载引擎执行推理,最后将预处理后的数据赋值给引擎输入执行推理。分别比较了改进前后的检测速度,其结果见表 4,检测时间为 0.035 66 s, FPS 为 28.04 帧/s,满足实时性要求。总体来看,改进后模型在检测速度基本不变的情况下,准确度提升了 3.86%。

表 4 边缘端检测速度对比

Table 4 Edge detection speed comparison

算法	检测时间/s	FPS/(帧·s <sup>-1</sup> )
YOLOv7-tiny	0.035 13	28.46
本文	0.035 66	28.04

为验证改进算法和 YOLOv7-tiny 算法在安全帽数据集上的检测效果,选取了不同光线下的密集场景进行对比,如图 7 所示。可以看出,改进后网络的识别度更高,相较于原网络漏检和误检的情况更少。由图 8 对应的热力图可以看出,改进后网络的热力图区域更大、分布更多,这意味着安全帽场景的检测效果更好。

4 结 语

针对当前安全帽检测准确率低的问题,本文提出了一种基于 YOLOv7-tiny 轻量级网络改进的目标检测算法。首先,鉴于矿工安全帽小目标较多,将主干网中提取的 160×160 大小特征层信息堆叠到颈部网络,以提高网络对安全帽小目标的检测能力。其次,在主干网和颈部网络之间加入 SimAM 注意力机制,提高矿工安全帽特征信息的提取能力。最后,





图 7 YOLOv7-tiny 算法和改进 YOLOv7-tiny 算法的检测效果  
Fig. 7 Detection effects of YOLOv7-tiny algorithm and improved YOLOv7-tiny algorithm

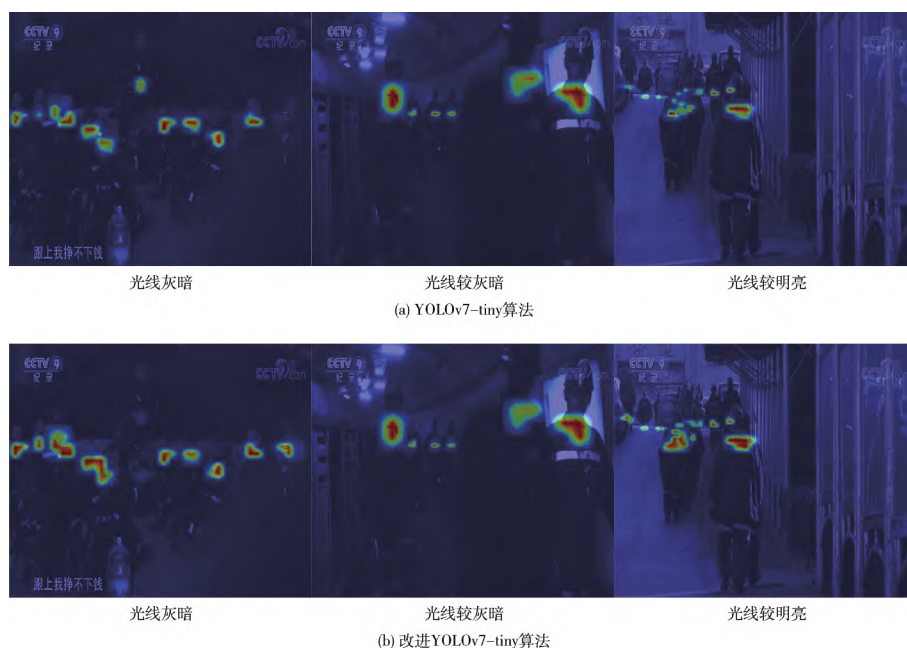


图 8 YOLOv7-tiny 算法和改进 YOLOv7-tiny 算法的热力图  
Fig. 8 Heatmap of YOLOv7-tiny algorithm and improved YOLOv7-tiny algorithm

使用 SIoU 损失函数替代 CIoU 损失函数,进一步提升了网络的准确率。在光线复杂的密集场景下,漏检和误检的情况更少,并且在 Jetson TX2 上检测速度可达 28.04 帧/s,满足实时性要求。本文算法在矿工安全帽数据集上相较于 YOLOv7-tiny 平均准确度均值提升了 3.86%,且效果优于同类型其他网络,充分证明了算法在安全帽检测方面的有效性。

未来的工作仍将聚焦于矿井场景下的安全帽检测,使算法在特殊场景下仍能保持良好的精度。

(由于印刷关系,查阅本文电子版请登录:<http://www.paper.edu.cn/journal/zgkjlw.shtml>)

#### [参考文献] (References)

- [1] 张心怡. 基于本体的矿工不安全行为判别方法研究[D]. 徐州: 中国矿业大学, 2020: 1-2.  
ZHANG X Y. Research on the method of miners' unsafe behavior identification based on ontology [D]. Xuzhou: China University of Mining and Technology, 2020: 1-2. (in Chinese)

(下转第 1274 页)

- low-light image enhancement [C] // 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2022: 17693-17703.
- [8] HAI J, XUAN Z, YANG R, et al. R2RNet: low-light image enhancement via real-low to real-normal network [J]. Journal of Visual Communication and Image Representation, 2023, 90: 103712.
- [9] HE K M, SUN J, TANG X O. Single image haze removal using dark channel prior [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33 (12): 2341-2353.
- [10] ZHU H G, WANG K, ZHANG Z W, et al. Low-light image enhancement network with decomposition and adaptive information fusion [J]. Neural Computing and Applications, 2022, 34(10): 7733-7748.
- [11] ZAMIR S W, ARORA A, KHAN S, et al. Learning enriched features for real image restoration and enhancement [C] // European Conference on Computer Vision. Cham: Springer, 2020: 492-511.
- [12] TANG H, ZHU H Y, FEI L F, et al. Low-illumination image enhancement based on deep learning techniques: a brief review [J]. Photonics, 2023, 10(2): 198.
- [13] LIU R S, MA L, MA T Y, et al. Learning with nested scene modeling and cooperative architecture search for low-light vision [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45 (5): 5953-5969.
- [14] REN J H, ZHANG Z, HONG R C, et al. Seeing through the noisy dark: towards real-world low-light image enhancement and denoising [EB/OL]. [2022-10-02]. <https://arxiv.org/abs/2210.00545>.
- [15] XUE X W, HE J, MA L, et al. Best of both worlds: see and understand clearly in the dark [C] // Proceedings of the 30th ACM International Conference on Multimedia. New York: ACM, 2022: 2154-2162.
- 
- (上接第 1256 页)
- [2] 徐先峰, 赵万福, 邹浩泉, 等. 基于 MobileNet-SSD 的安全帽佩戴检测算法[J]. 计算机工程, 2021, 47(10): 298-305, 313.  
XU X F, ZHAO W F, ZOU H Q, et al. Detection algorithm of safety helmet wear based on MobileNet-SSD [J]. Computer Engineering, 2021, 47(10): 298-305, 313. (in Chinese)
- [3] 郭奕裕, 周笋鱼. 安全帽佩戴检测网络模型的轻量化设计[J]. 计算机工程, 2023, 49(4): 312-320.  
GUO Y Y, ZHOU L Y. Lightweight design of safety helmet wearing detection network model [J]. Computer Engineering, 2023, 49(4): 312-320. (in Chinese)
- [4] 李嘉信, 胡杨, 黄协舟, 等. 面向小目标的多空间层次安全帽检测 [J/OL]. [2022-12-19]. <https://kns.cnki.net/kcms/detail/11.2127.TP.20221129.1158.004.html>.  
LI J X, HU Y, HUANG X Z, et al. Small target-oriented multi-space hierarchical helmet detection [J/OL]. [2022-12-19]. <https://kns.cnki.net/kcms/detail/11.2127.TP.20221129.1158.004.html>. (in Chinese)
- [5] 张翼翔, 林松, 李雪. 基于 CenterNet-GhostNet 的选煤厂危险区域人员检测[J]. 工矿自动化, 2022, 48(4): 66-71.  
ZHANG Y X, LIN S, LI X. Personnel detection in dangerous area of coal preparation plant based on CenterNet-GhostNet [J]. Journal of Mine Automation, 2022, 48(4): 66-71. (in Chinese)
- [6] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C] // 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2023: 7464-7475.
- [7] YANG L X, ZHANG R Y, LI L D, et al. SimAM: a simple, parameter-free attention module for convolutional neural networks [C] // Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021: 11863-11874.
- [8] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized intersection over union: a metric and a loss for bounding box regression [C] // 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2020: 658-666.
- [9] ZHENG Z H, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(7): 12993-13000.
- [10] ZHENG Z H, WANG P, REN D W, et al. Enhancing geometric factors in model learning and inference for object detection and instance segmentation [J]. IEEE Transactions on Cybernetics, 2022, 52(8): 8574-8586.
- [11] GEVORGYAN Z. Siou loss: more powerful learning for bounding box regression [EB/OL]. [2022-06-07]. <https://arxiv.org/abs/2205.12740>. pdf.
- [12] SHI Y, WU J, ZHAO S X, et al. Rethinking the detection head configuration for traffic object detection [EB/OL]. [2022-12-10]. <https://arxiv.org/abs/2210.03883>. pdf.